(2)轻松玩转书生·浦语大模型趣味 Demo

视频链接: 【(2)轻松玩转书生·浦语大模型趣味 Demo】

https://www.bilibili.com/video/BV1Ci4y1z72H

讲义链接: https://github.com/InternLM/tutorial/blob/main/helloworld/hello_world.md

课程内容:

1. 开发机环境配置

可以通过脚本一键复制成熟的开发环境

bash /root/share/install_conda_env_internIm_base.sh internIm-demo

2. 模型下载:

可以直接拷贝平台下载好的模型,或者通过 modelscope, huggingface 等工具下载。

3. 终端运行:

可以执行 cli_demo.py 文件, 在开发机通过命令行输入的方式交互,

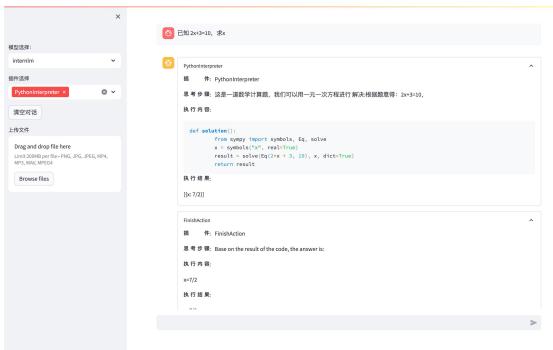


或者执行 web_demo.py 文件,在开发机启动进程后,通过端口映射到本地,在浏览器里访问模型对话的页面进行交互。



4. Lagent 智能体工具调用 demo

Lagent 其实就是在大模型的基础上,可以允许智能体处理多种形式的输入(图像,文字,音频,视频)等,然后可以让大模型理解用户输入后,调用对应的插件 plugin 来执行用户的意图。这其实就类似于个人助手的概念了。



执行效果如图,输入该数学问题给大模型,大模型理解题意后,使用 python 解释器编程,解答了该数学问题。

在部署时遇到了一个问题: 虽然在开发机上加载 InternLM-Chat-7B 最终占用的显存空间不满 1/4 个 A100 卡, 但是当我使用 1/4 卡的开发机配置部署 lagent demo 时, 总是会报错显存不足, 然后我调整配置为 2 张 1/4 卡, 这样就可以部署成功了, 不知道为什么会有这样的报错。

5. 浦语·灵笔图文理解创作 Demo

根据我的理解, 浦语·灵笔是一种处理多模态输入输出的智能体, 加载的不只有大语言模型, 还有视觉, 语音模型等等, 可以综合处理文本和图片的输入并且以图片+文字的形式进行输出。这证明视觉和语言大模型的语义是可以对齐的。

下面是 internlm-xcomposer 的两种 demo, 第一种是根据文字主题输入, 输出图文结合的 宣传文案, 第二个则是接受图片输入, 然后看图回答问题。

中文

InternLM-XComposer





Use via API 💉 · 使用Gradio构建 😣